

SPRINT 01 | PT-BR & EN

Trilha Acadêmica | Bruna Brasil

Versão PT-BR

Entregáveis:

- Tema de pesquisa claramente definido
- Título provisório
- Justificativas iniciais

A seguir, serão apresentados os entregáveis elaborados.

Tema de Pesquisa

O projeto consiste em uma avaliação experimental da capacidade técnica e integridade ética de modelos de Machine Learning no setor financeiro, focando especificamente na falha de generalização causada pela dependência excessiva de dados históricos. A pesquisa investigará o fenômeno do "data drift" (deriva de dados), onde algoritmos treinados em períodos de estabilidade perdem precisão e confiabilidade ao enfrentar cenários de alta volatilidade e crises econômicas. O experimento mapeará como essa degradação de performance técnica impacta a explicabilidade (XAI) das decisões e se a instabilidade do mercado amplifica vieses algorítmicos e riscos regulatórios

Título Provisório

"Resiliência e Ética em Sistemas de Decisão: Uma Análise Experimental da Performance e Explicabilidade (XAI) de Modelos de Machine Learning sob Alta Volatilidade Financeira."

Justificativas Iniciais

1. Lacuna na Capacidade de Generalização: Artigos de revisão apontam que modelos financeiros modernos (como Random Forest e Redes Neurais) apresentam alta precisão em períodos estáveis, mas possuem uma dependência crítica de dados históricos estáticos. Isso gera um gap de performance quando o modelo enfrenta mudanças repentinas de mercado ou eventos sem precedentes, tornando necessária uma análise que mapeie esses pontos de falha.

2. O Problema da "Caixa-Preta" e Riscos Regulatórios: A natureza opaca (black-box) de algoritmos complexos impede a rastreabilidade da decisão, o que é um entrave para o cumprimento de normas regulatórias e para a confiança dos usuários. O uso de Inteligência

Artificial Explicável (XAI) é uma trajetória recomendada para mitigar riscos de responsabilidade jurídica e garantir transparência.

3. Amplificação de Vieses em Cenários de Crise: Existe a evidência de que a falta de representatividade nos dados e a instabilidade do mercado podem levar algoritmos a reforçar desigualdades sociais (vieses) em decisões como a concessão de crédito. Documentar experimentalmente como a volatilidade afeta a justiça (fairness) do modelo constitui um achado novo e relevante para a governança de IA.

4. Viabilidade e Rigor Metodológico: A Pesquisa Experimental é a metodologia mais consolidada para controlar variáveis e determinar causas e efeitos no processamento de dados. Através de ferramentas existentes e datasets históricos, é possível produzir resultados científicos robustos sem a necessidade de desenvolvimento de infraestrutura de software do zero.

English Version

Research Theme

The project consists of an experimental evaluation of the technical robustness and ethical integrity of Machine Learning models in the financial sector, specifically focusing on generalization failures caused by an excessive dependency on historical data. The research will investigate the phenomenon of "data drift" (performance decay), where algorithms trained during periods of stability lose precision and reliability when facing scenarios of high volatility and economic crises. The experiment will map how this technical performance degradation impacts the explainability (XAI) of decisions and whether market instability amplifies algorithmic biases and regulatory risks.

Provisional Title

"Resilience and Ethics in Decision Systems: An Experimental Analysis of the Performance and Explainability (XAI) of Machine Learning Models under High Financial Volatility."

Initial Justifications

1. Gap in Generalization Capacity: Review articles indicate that modern financial models (such as Random Forest and Neural Networks) demonstrate high accuracy in stable periods but possess a critical dependency on static historical data. This creates a performance gap

when the model encounters sudden market changes or unprecedented events, making it necessary to conduct an analysis that maps these failure points.

2. The "Black-Box" Problem and Regulatory Risks: The opaque (black-box) nature of complex algorithms prevents decision traceability, which is a major barrier to regulatory compliance and user trust. The use of Explainable Artificial Intelligence (XAI) is a recommended trajectory to mitigate legal liability risks and ensure transparency.

3. Amplification of Biases in Crisis Scenarios: There is evidence that a lack of representativeness in training data and market instability can lead algorithms to reinforce social inequalities (biases) in critical decisions, such as credit granting. Documenting experimentally how volatility affects model fairness constitutes a relevant "new finding" for AI governance.

4. Feasibility and Methodological Rigor: Experimental Research is the most consolidated methodology for controlling variables and determining causes and effects in data processing. By using existing tools (such as Python libraries for XAI like SHAP or LIME) and historical datasets, it is possible to produce robust scientific results without the need to develop new software infrastructure from scratch.